# Байесовский выбор моделей: Вариационный EM-алгоритм

Александр Адуенко

10е ноября 2026

# Содержание предыдущих лекций

- Формула Байеса и формула полной вероятности;
- Определение априорных вероятностей и selection bias;
- (Множественное) тестирование гипотез
- Экспоненциальное семейство. Достаточные статистики.
- Наивный байесовский классификатор. Связь целевой функции и вероятностной модели.
- Линейная регрессия: связь МНК и $\mathbf{w}_{\text{ML}}$, регуляризации и $\mathbf{w}_{\text{MAP}}$.
- Свойство сопряженности априорного распределения правдоподобию.
- Прогноз для одиночной модели:
$$p(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}, \mathbf{X}_{\text{train}}, \mathbf{y}_{\text{train}}) = \int p(\mathbf{y}_{\text{test}}|\mathbf{w}, \mathbf{X}_{\text{test}})p(\mathbf{w}|\mathbf{X}_{\text{train}}, \mathbf{y}_{\text{train}})d\mathbf{w}.$$
- Связь апостериорной вероятности модели и обоснованности
- Обоснованность: понимание и связь со статистической значимостью.
- Логистическая регрессия: проблемы ML-оценки $\mathbf{w}$; связь априорного распределения с отбором признаков.
- Неопределенность в прогнозе и апостериорное распределение; учёт нелинейных зависимостей, пропусков и выбросов.
- EM-алгоритм. Использование EM-алгоритма для отбора признаков в байесовской линейной регрессии.

# EM-алгоритм: воспоминание

Пусть $\mathbf{D} = (\mathbf{X}, \mathbf{y})$ – наблюдаемые переменные, $\mathbf{Z}$ – скрытые переменные. $p(\mathbf{D}, \mathbf{Z}|\mathbf{\Theta}) = p(\mathbf{D}|\mathbf{Z}, \mathbf{\Theta})p(\mathbf{Z}|\mathbf{\Theta})$.

**Вопрос 1:** как решить задачу $p(\mathbf{D}|\mathbf{\Theta}) = \int p(\mathbf{D}, \mathbf{Z}|\mathbf{\Theta})d\mathbf{Z} \to \max\limits_{\mathbf{\Theta}}$?

EM-алгоритм

Введем $F(q, \mathbf{\Theta}) = -\int q(\mathbf{Z}) \log q(\mathbf{Z})d\mathbf{Z} + \int q(\mathbf{Z}) \log p(\mathbf{D}, \mathbf{Z}|\mathbf{\Theta})d\mathbf{Z} =$

$-\int q(\mathbf{Z}) \log q(\mathbf{Z})d\mathbf{Z} + \int q(\mathbf{Z}) \log p(\mathbf{Z}|\mathbf{D}, \mathbf{\Theta})d\mathbf{Z} + \int \log p(\mathbf{D}|\mathbf{\Theta})q(\mathbf{Z})d\mathbf{Z} =$

$\log p(\mathbf{D}|\mathbf{\Theta}) - \int q(\mathbf{Z}) \log \frac{q(\mathbf{Z})}{p(\mathbf{Z}|\mathbf{D},\mathbf{\Theta})}d\mathbf{Z} = \log p(\mathbf{D}|\mathbf{\Theta}) - D_{\mathrm{KL}}(q\|p(\mathbf{Z}|\mathbf{D}, \mathbf{\Theta}))$.

**Идея 1:** $p(\mathbf{D}|\mathbf{\Theta}) \to \max\limits_{\mathbf{\Theta}}$ заменим на $F(q, \mathbf{\Theta}) \to \max\limits_{q,\, \mathbf{\Theta}}$.

**Идея 2:** Пошагово оптимизируем по $\mathbf{\Theta}$ и $q$, то есть

1. E-шаг: $q^s = F(q, \mathbf{\Theta}^{s-1}) \to \max\limits_{q \in Q}$;
2. M-шаг: $\mathbf{\Theta}^s = F(q^s, \mathbf{\Theta}) \to \max\limits_{\mathbf{\Theta}}$.

**Вопрос:** Зачем $q \in Q$? Как E-шаг был выполнен при максимизации обоснованности для модели линейной регрессии?

# EM-алгоритм для максимизации обоснованности

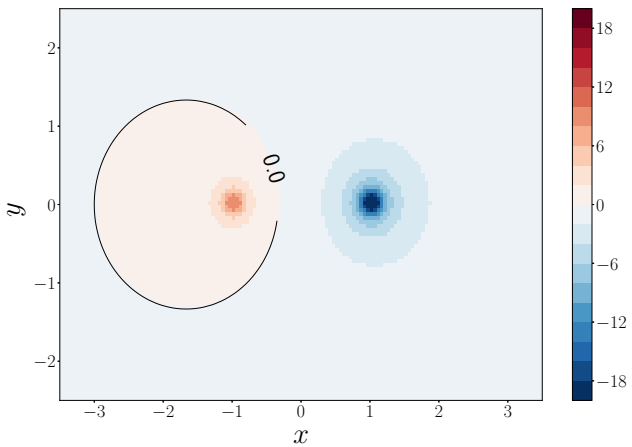
**Потенциал поля точечного заряда:** $\varphi = k\frac{q}{r}$.

Пусть имеется несколько зарядов $q_1, \ldots, q_l$ в точках $\mathbf{z}_1, \ldots, \mathbf{z}_l$.

Тогда $\varphi(\mathbf{x}) = k\sum\limits_{i=1}^{l}\frac{q_l}{\|\mathbf{x}-\mathbf{z}_l\|}$. По набору точек $\mathbf{x}_1, \ldots, \mathbf{x}_m$ и измеренным

$$y_i = \varphi(\mathbf{x}_i) - \underbrace{\varphi(\infty)}_{=0} + \varepsilon_i,\ \varepsilon_i \sim \mathcal{N}(\varepsilon_i|0,\ \beta^{-1})$$

**требуется** оценить $\varphi(\mathbf{x})$ для $\mathbf{x}$ из тестовой выборки.




$$\mathbf{y} = \mathbf{\Phi}\mathbf{w} + \boldsymbol{\varepsilon},\ \boldsymbol{\varepsilon} \sim \mathcal{N}(\boldsymbol{\varepsilon}|\mathbf{0},\ \beta^{-1}\mathbf{I}),\ \text{где}$$
$$\mathbf{\Phi} = \left\|\frac{1}{\delta+\|\mathbf{x}_i-\mathbf{x}_j\|}\right\|,\ i,\ j = \overline{1,\ m};$$
$$\mathbf{w} \sim p(\mathbf{w}|\mathbf{A}) = \mathcal{N}(\mathbf{w}|\mathbf{0},\ \mathbf{A}^{-1}).$$

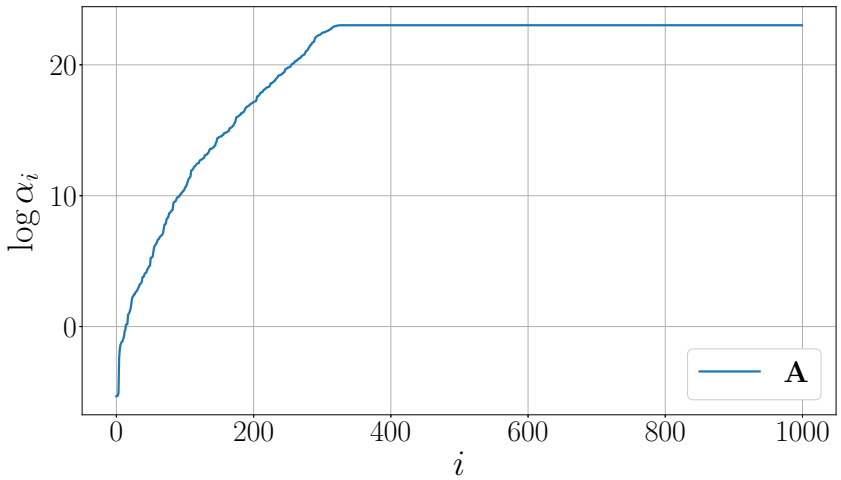
**Шаг 1:** $p(\mathbf{y}_{\text{train}}|\mathbf{\Phi}_{\text{train}},\ \mathbf{A},\ \beta) \to \max\limits_{\mathbf{A},\,\beta}$ позволит отобрать признаки.

**Шаг 2:** Прогноз для тестовой выборки:

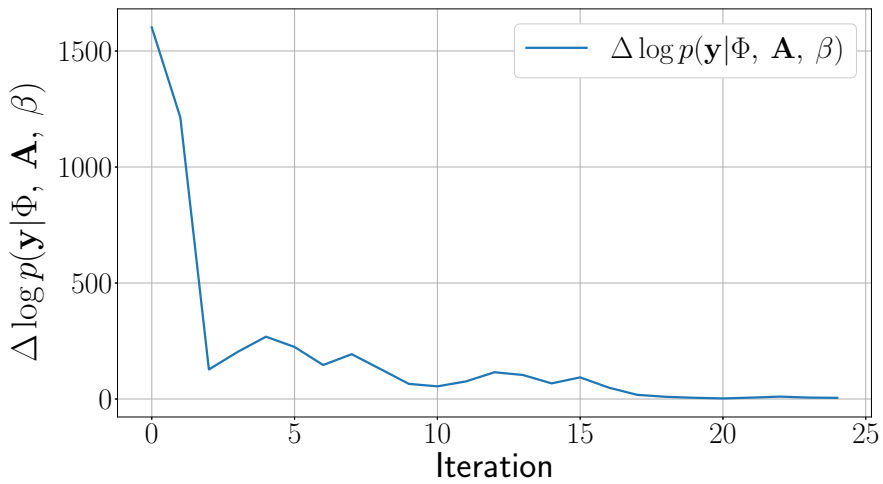
$$p(\mathbf{y}_{\text{test}}|\mathbf{\Phi}_{\text{test}},\ \mathbf{\Phi}_{\text{train}},\ \mathbf{y}_{\text{train}}) = \int p(\mathbf{y}_{\text{test}}|\mathbf{w},\ \mathbf{\Phi}_{\text{test}})p(\mathbf{w}|\mathbf{\Phi}_{\text{train}},\ \mathbf{y}_{\text{train}})d\mathbf{w}$$

# Результаты для задачи восстановления потенциала

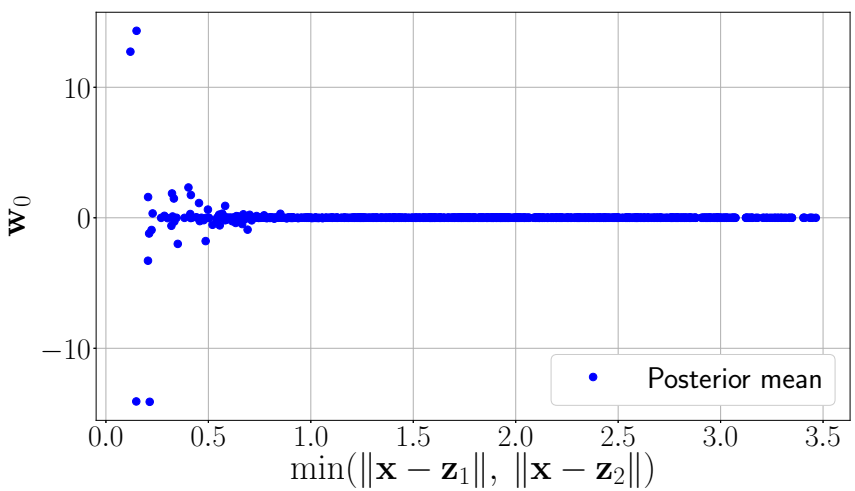
## Оптимальный $\boldsymbol{\alpha}$



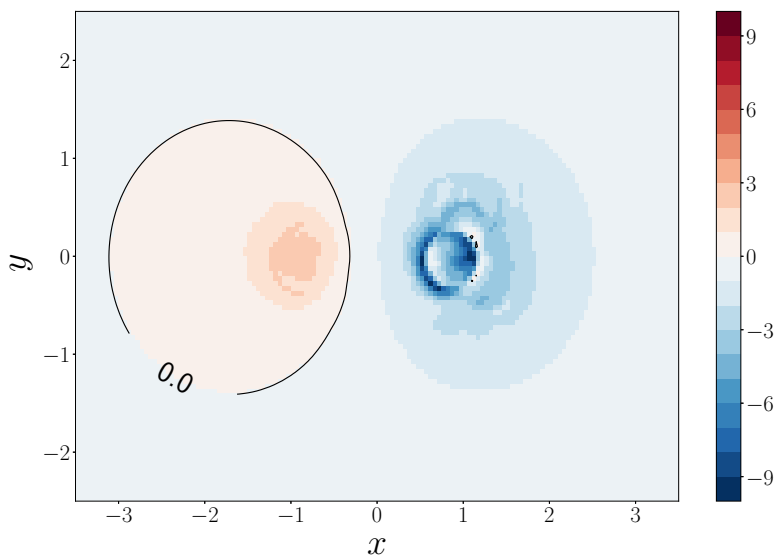

## Обоснованность по итерациям




## Среднее апостериорного распределения $\mathbf{w}_0$




## Восстановленный потенциал



# Вариационный EM-алгоритм. E-шаг

$$F(q,\ \boldsymbol{\Theta}^{s-1}) \to \max_{q\in Q} \Longleftrightarrow D_{\mathrm{KL}}(q\|p(\mathbf{Z}|\mathbf{D},\ \boldsymbol{\Theta})) \to \min_{q\in Q}.$$

$$D_{\mathrm{KL}}(q\|p(\mathbf{Z}|\mathbf{D},\ \boldsymbol{\Theta})) = \log p(\mathbf{D}|\boldsymbol{\Theta}) + \int q(\mathbf{Z}) \log \frac{q(\mathbf{Z})}{p(\mathbf{D},\ \mathbf{Z}|\boldsymbol{\Theta})} d\mathbf{Z}.$$

Пусть $Q = \left\{ q :\ q(\mathbf{Z}) = \prod_{k=1}^{K} q(\mathbf{Z}_k) \right\}$, тогда

$$D_{\mathrm{KL}}(q\|p(\mathbf{Z}|\mathbf{D},\ \boldsymbol{\Theta})) \propto \int \prod_{k=1}^{K} q(\mathbf{Z}_k) \log \frac{\prod_{j=1}^{K} q(\mathbf{Z}_j)}{p(\mathbf{D},\ \mathbf{Z}_1,\ \ldots,\ \mathbf{Z}_K|\boldsymbol{\Theta})} d\mathbf{Z}_1 \ldots d\mathbf{Z}_K =$$

$$\int q(\mathbf{Z}_k) \log q(\mathbf{Z}_k) \underbrace{\left[ \prod_{j\neq k} \int q(\mathbf{Z}_j) d\mathbf{Z}_j \right]}_{=1} d\mathbf{Z}_k + \sum_{j\neq k} C_j \underbrace{\int q(\mathbf{Z}_k) d\mathbf{Z}_k}_{=1} -$$

$$\int q(\mathbf{Z}_k) \underbrace{\left[ \int \prod_{j\neq k} q(\mathbf{Z}_j) \log p(\mathbf{D},\ \mathbf{Z}_1,\ \ldots,\ \mathbf{Z}_K|\boldsymbol{\Theta}) d\mathbf{Z}_{j\neq k} \right]}_{\mathsf{E}_{q\setminus k} \log p(\mathbf{D},\mathbf{Z}|\boldsymbol{\Theta})} d\mathbf{Z}_k \propto$$

$$\int q(\mathbf{Z}_k) \log \frac{q(\mathbf{Z}_k)}{\frac{1}{C} e^{\mathsf{E}_{q\setminus k} \log p(\mathbf{D},\mathbf{Z}|\boldsymbol{\Theta})}} d\mathbf{Z}_k \to \min_{q(\mathbf{Z}_k)}.$$

# Вариационный EM-алгоритм

$$F(q,\, \boldsymbol{\Theta}) = \int q(\mathbf{Z}) \log \frac{p(\mathbf{D},\, \mathbf{Z}|\boldsymbol{\Theta})}{q(\mathbf{Z})} d\mathbf{Z} = \log p(\mathbf{D}|\boldsymbol{\Theta}) - D_{\mathrm{KL}}(q \| p(\mathbf{Z}|\mathbf{D},\, \boldsymbol{\Theta})).$$

**E-шаг.** $\displaystyle\int q(\mathbf{Z}_k) \log \frac{q(\mathbf{Z}_k)}{\frac{1}{C} e^{\mathsf{E}_{q \setminus k} \log p(\mathbf{D},\, \mathbf{Z}|\boldsymbol{\Theta})}} d\mathbf{Z}_k \to \min_{q(\mathbf{Z}_k)}.$

**Полный алгоритм**

Пошагово оптимизируем по $\boldsymbol{\Theta}$ и $q(\mathbf{Z}_k)$, $k = 1, \ldots, K$, то есть

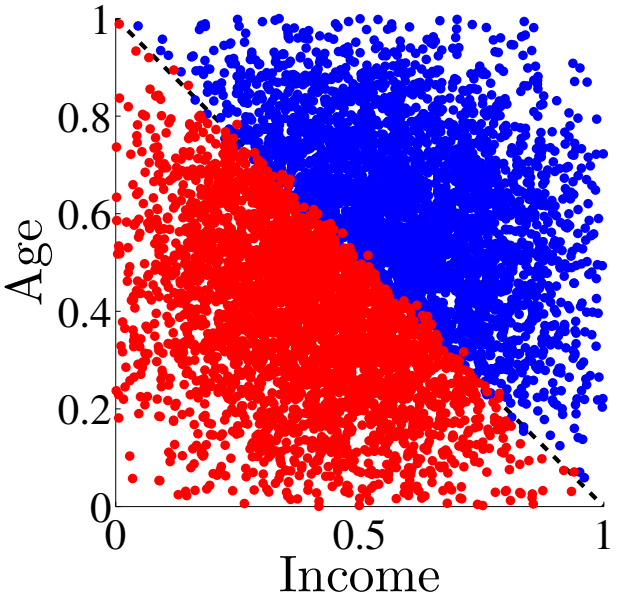
1. E-шаг: $\log q(\mathbf{Z}_k^s) \propto \mathsf{E}_{q \setminus k} \log p(\mathbf{D},\, \mathbf{Z}|\boldsymbol{\Theta}^{s-1})$;
2. M-шаг: $\mathsf{E}_{q^s} \log p(\mathbf{D},\, \mathbf{Z}|\boldsymbol{\Theta}) \to \max\limits_{\boldsymbol{\Theta}}$.

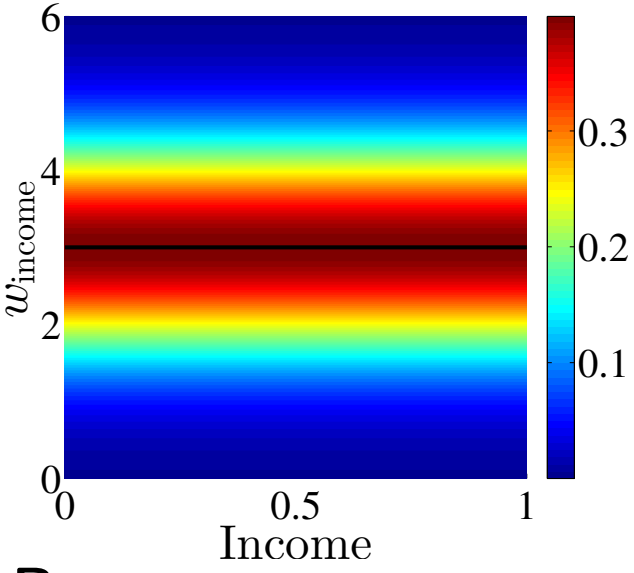
**Вопрос 1:** Зачем нужна факторизация? Чем полученные итеративные формулы лучше формул полного EM-алгоритма?

**Вопрос 2:** Как понять, что в конкретной задаче формулы E и M-шагов выписаны верно?

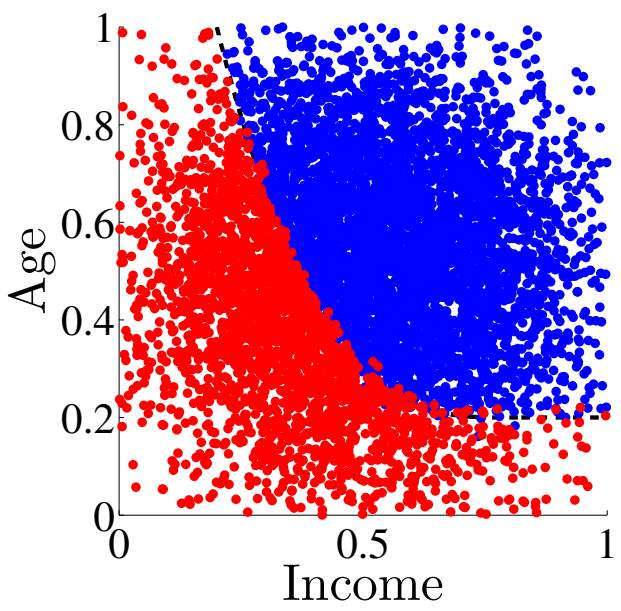
# Нарушение свойства $p(\mathbf{w}|\mathbf{x}_i) = p(\mathbf{w})$

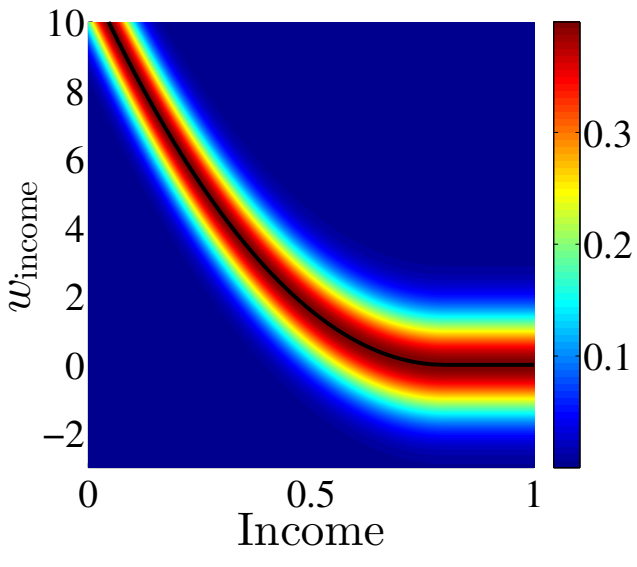
## Предполагаемый результат




## Реальные данные




**Вопрос:** как можно учесть указанную нелинейность в модели?

# Смесь моделей логистической регрессии

## Вероятностная модель генерации данных

- Веса моделей в смеси $\boldsymbol{\pi}$ получены из априорного распределения $p(\boldsymbol{\pi}|\mu)$;
- Векторы параметров моделей $\mathbf{w}_k$ получены из нормального распределения $p(\mathbf{w}_k|\mathbf{A}_k) = \mathcal{N}(\mathbf{w}_k|\mathbf{0},\ \mathbf{A}_k^{-1}),\ k = 1, \ldots, K$;
- Для каждого объекта $\mathbf{x}_i$ выбрана модель $f_{k_i}$, которой он описывается, причем $p(k_i = k) = \pi_k$;
- Для каждого объекта $\mathbf{x}_i$ класс $y_i$ определен в соответствии с моделью $f_{k_i}$: $y_i \sim \mathrm{Be}\big(\sigma(\mathbf{w}_{k_i}^{\mathsf{T}}\mathbf{x}_i)\big)$.

## Совместное правдоподобие модели

$$p(\mathbf{y},\ \mathbf{w}_1,\ \ldots,\ \mathbf{w}_K,\ \boldsymbol{\pi}|\mathbf{X},\ \mathbf{A}_1,\ \ldots,\ \mathbf{A}_K,\ \boldsymbol{\mu}) =$$

$$p(\boldsymbol{\pi}|\boldsymbol{\mu}) \prod_{k=1}^{K} \mathcal{N}(\mathbf{w}_k|\mathbf{0},\ \mathbf{A}_k^{-1}) \prod_{i=1}^{m} \left( \sum_{l=1}^{K} \pi_l \sigma(y_i \mathbf{w}_l^{\mathsf{T}} \mathbf{x}_i) \right).$$

Введем матрицу скрытых переменных $\mathbf{Z} = \|z_{ik}\|$, где $z_{ik} = 1 \Longleftrightarrow k_i = k$.

$$p(\mathbf{y},\ \mathbf{w}_1,\ \ldots,\ \mathbf{w}_K,\ \boldsymbol{\pi},\ \mathbf{Z}|\mathbf{X},\ \mathbf{A}_1,\ \ldots,\ \mathbf{A}_K,\ \boldsymbol{\mu}) =$$

$$p(\boldsymbol{\pi}|\boldsymbol{\mu}) \prod_{k=1}^{K} \mathcal{N}(\mathbf{w}_k|\mathbf{0},\ \mathbf{A}_k^{-1}) \prod_{i=1}^{m} \prod_{l=1}^{K} \left( \pi_l \sigma(y_i \mathbf{w}_l^{\mathsf{T}} \mathbf{x}_i) \right)^{z_{il}}.$$

# Получение MAP-оценки

Пусть $p(\boldsymbol{\pi}|\boldsymbol{\mu}) = \mathrm{Dir}(\boldsymbol{\mu}) = \dfrac{\Gamma(\sum_k \mu_k)}{\prod_l \Gamma(\mu_l)} \prod_k \pi_k^{\mu_k - 1}$.

$$p(\mathbf{y},\, \mathbf{w}_1,\, \ldots,\, \mathbf{w}_K,\, \boldsymbol{\pi},\, \mathbf{Z}|\mathbf{X},\, \mathbf{A}_1,\, \ldots,\, \mathbf{A}_K,\, \boldsymbol{\mu}) \propto$$

$$\prod_{k=1}^{K} \pi_k^{\mu_k - 1} \prod_{k=1}^{K} \sqrt{\det \mathbf{A}_k} \exp(-\tfrac{1}{2}\mathbf{w}_k^{\mathsf{T}} \mathbf{A}_k \mathbf{w}_k) \prod_{i=1}^{m} \prod_{l=1}^{K} \Big(\pi_l \sigma(y_i \mathbf{w}_l^{\mathsf{T}} \mathbf{x}_i)\Big)^{z_{il}}.$$

$$(\boldsymbol{\pi}^*, \mathbf{w}_1^*, \ldots, \mathbf{w}_K^*) = \arg \max_{\boldsymbol{\pi},\, \mathbf{w}_1,\, \ldots,\, \mathbf{w}_K} p(\mathbf{y}, \mathbf{w}_1, \ldots, \mathbf{w}_K, \boldsymbol{\pi}|\mathbf{X}, \mathbf{A}_1, \ldots, \mathbf{A}_K, \boldsymbol{\mu}).$$

**E-шаг**. $\log q(\mathbf{Z}) \propto \sum_{i=1}^{m} \sum_{l=1}^{K} z_{il} (\log \pi_l + \log \sigma(y_i \mathbf{w}_l^{\mathsf{T}} \mathbf{x}_i))$, откуда

$$\gamma_{ik} = p(z_{ik} = 1) \propto \pi_k \sigma(y_i \mathbf{w}_k^{\mathsf{T}} \mathbf{x}_i).$$

**M-шаг**. $\mathsf{E}_q \log p(\mathbf{y},\, \mathbf{w}_1,\, \ldots,\, \mathbf{w}_K,\, \boldsymbol{\pi},\, \mathbf{Z}|\mathbf{X},\, \mathbf{A}_1,\, \ldots,\, \mathbf{A}_K,\, \boldsymbol{\mu}) \to \max_{\boldsymbol{\pi},\, \mathbf{w}_1,\, \ldots,\, \mathbf{w}_K}$.

$$\mathbf{w}_k^* = \arg\max_{\mathbf{w}_k} \left[ -\tfrac{1}{2}\mathbf{w}_k^{\mathsf{T}} \mathbf{A}_k \mathbf{w}_k + \sum_{i=1}^{m} \gamma_{ik} \log \sigma(y_i \mathbf{w}_k^{\mathsf{T}} \mathbf{x}_i) \right].$$

$$\boldsymbol{\pi}^* = \arg\max_{\boldsymbol{\pi}} \sum_{k=1}^{K} \log \pi_k \Big( \underbrace{\sum_{i=1}^{m} \gamma_{ik}}_{\gamma_k} + \mu_k - 1 \Big) \Longrightarrow \pi_k \propto \max(0,\, \gamma_k + \mu_k - 1).$$

# Получение апостериорного распределения

**Вопрос:** как получить $p(\mathbf{w}_1, \ldots, \mathbf{w}_k, \boldsymbol{\pi} | \mathbf{X}, \mathbf{y}, \mathbf{A}_1, \ldots, \mathbf{A}_K, \boldsymbol{\mu})$?

$$p(\mathbf{y}, \mathbf{w}_1, \ldots, \mathbf{w}_K, \boldsymbol{\pi} | \mathbf{X}, \mathbf{A}_1, \ldots, \mathbf{A}_K, \boldsymbol{\mu}) \propto$$
$$\prod_{k=1}^{K} \pi_k^{\mu_k - 1} \prod_{k=1}^{K} \sqrt{\det \mathbf{A}_k} \exp(-\tfrac{1}{2} \mathbf{w}_k^{\mathsf{T}} \mathbf{A}_k \mathbf{w}_k) \prod_{i=1}^{m} \left( \sum_{l=1}^{K} \pi_l \sigma(y_i \mathbf{w}_l^{\mathsf{T}} \mathbf{x}_i) \right).$$

**Идея:** найдем $q(\mathbf{Z}, \mathbf{w}_1, \ldots, \mathbf{w}_K, \boldsymbol{\pi}) = q(\mathbf{Z}) q(\mathbf{w}_1, \ldots, \mathbf{w}_K) q(\boldsymbol{\pi})$, наиболее близкое к $p(\mathbf{w}_1, \ldots, \mathbf{w}_k, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{y})$.

$$\log q(\mathbf{Z}) \propto \mathsf{E}_{q_{\setminus \mathbf{Z}}} \log p(\mathbf{y}, \mathbf{w}_1, \ldots, \mathbf{w}_K, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}_1, \ldots, \mathbf{A}_K, \boldsymbol{\mu}) \propto$$
$$\sum_{i=1}^{m} \sum_{k=1}^{K} z_{ik} \left( \mathsf{E} \log \pi_k + \mathsf{E} \log \sigma(y_i \mathbf{w}_k^{\mathsf{T}} \mathbf{x}_i) \right)$$
$$\Longrightarrow p(z_{ik} = 1) \propto \exp \left( \mathsf{E} \log \pi_k + \mathsf{E} \log \sigma(y_i \mathbf{w}_k^{\mathsf{T}} \mathbf{x}_i) \right).$$

$$\log q(\boldsymbol{\pi}) \propto \mathsf{E}_{q_{\setminus \boldsymbol{\pi}}} \log p(\mathbf{y}, \mathbf{w}_1, \ldots, \mathbf{w}_K, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}_1, \ldots, \mathbf{A}_K, \boldsymbol{\mu}) \propto$$
$$\sum_{k=1}^{K} \log \pi_k \left( \mu_k - 1 + \sum_{i=1}^{m} \mathsf{E} z_{ik} \right) \Longrightarrow \boldsymbol{\pi} \sim \mathrm{Dir}(\boldsymbol{\mu} + \boldsymbol{\gamma}).$$

# Получение апостериорного распределения (продолжение)

$$\log q(\mathbf{w}_1, \ldots, \mathbf{w}_K) \propto \mathsf{E}_{q_{\setminus \mathbf{w}}} \log p(\mathbf{y}, \mathbf{w}_1, \ldots, \mathbf{w}_K, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}_1, \ldots, \mathbf{A}_K, \boldsymbol{\mu}) \propto$$

$$\sum_{k=1}^{K} \left( -\tfrac{1}{2} \mathbf{w}_k^{\mathsf{T}} \mathbf{A}_k \mathbf{w}_k + \sum_{i=1}^{m} \mathsf{E} z_{ik} \log \sigma(y_i \mathbf{w}_k^{\mathsf{T}} \mathbf{x}_i) \right) = \sum_{k=1}^{K} f_k(\mathbf{w}_k).$$

**Вопрос 1:** Какую структуру имеет $q(\mathbf{w}_1, \ldots, \mathbf{w}_K)$ ?

**Вопрос 2:** Какой вид имеет распределение $q(\mathbf{w}_k)$?

Варианты аппроксимации $q(\mathbf{w}_k)$:

- Аппроксимация Лапласа: $q(\mathbf{w}_k) \approx \mathcal{N}(\mathbf{w}_k^*, \boldsymbol{\Sigma}_k^{-1})$;
- Ищем $q(\mathbf{w}_k) = \mathcal{N}(\mathbf{m}_k, \boldsymbol{\Sigma}_k^{-1})$ такое, что $D_{KL}(q \| C_k f_k(\mathbf{w}_k)) \to \min\limits_q$
  - Численно (если число признаков $n$ невелико);
  - С помощью VLB для сигмоиды и соответствующей верхней оценки для $D_{KL}(q \| C_k f_k(\mathbf{w}_k))$.

**Вопрос 3:** Как определить $\mathbf{A}_1, \ldots, \mathbf{A}_K, \boldsymbol{\mu}$?

# Определение гиперпараметров смеси моделей

## Максимизация обоснованности

$p(\mathbf{y}|\mathbf{X}, \mathbf{A}_1, \ldots, \mathbf{A}_K, \boldsymbol{\mu}) \to \max_{\mathbf{A}_1, \ldots, \mathbf{A}_K, \{\boldsymbol{\mu}\}}$

**Идея:** воспользуемся вариационным EM-алгоритмом.

**E-шаг:** найдем $q(\mathbf{Z}, \mathbf{w}_1, \ldots, \mathbf{w}_K, \boldsymbol{\pi}) = q(\mathbf{Z})q(\mathbf{w}_1, \ldots, \mathbf{w}_K)q(\boldsymbol{\pi})$, наиболее близкое к $p(\mathbf{w}_1, \ldots, \mathbf{w}_k, \boldsymbol{\pi}, \mathbf{Z}|\mathbf{X}, \mathbf{y})$.

**M-шаг:** $\mathsf{E}_q \log p(\mathbf{y}, \mathbf{w}_1, \ldots, \mathbf{w}_K, \boldsymbol{\pi}, \mathbf{Z}|\mathbf{X}, \mathbf{A}_1, \ldots, \mathbf{A}_K, \boldsymbol{\mu}) \to \max_{\mathbf{A}_1, \ldots, \mathbf{A}_K}$.

$$\sum_{k=1}^{K}\left[\sum_{j=1}^{n} \log \alpha_k^j - \alpha_k^j \mathsf{E} w_{kj}^2\right] \to \max_{\alpha_{11}, \ldots, \alpha_{Kn}}, \text{ где } \mathbf{A}_k = \operatorname{diag}(\alpha_{k1}, \ldots, \alpha_{kn}).$$

$\alpha_{kj} = \dfrac{1}{\mathsf{E} w_{kj}^2}$. **Hint:** $\alpha_{kj} = \dfrac{1 - \alpha_{kj}^{\text{old}} \mathsf{D} w_{kj}}{\mathsf{E}^2 w_{kj}}$.

**Вопрос:** Как получить $\mathsf{E} w_{kj}$ и $\mathsf{D} w_{kj}$?

**Замечание:** можно сразу сделать использовать VLB для сигмоидной функции, чтобы получить нижнюю границу обоснованности
$p(\mathbf{y}|\mathbf{X}, \mathbf{A}_1, \ldots, \mathbf{A}_K, \boldsymbol{\mu}) \geq \tilde{p}(\mathbf{y}|\mathbf{X}, \mathbf{A}_1, \ldots, \mathbf{A}_K, \boldsymbol{\mu})$
и тогда на E-шаге автоматически $q(\mathbf{w}_k)$ будет нормальным.

# Литература


1. Bishop, Christopher M. "Pattern recognition and machine learning". Springer, New York (2006). Pp. 113-120, 161-171, 498-505.
2. MacKay, David JC. Bayesian methods for adaptive models. Diss. California Institute of Technology, 1992.
3. Gelman, Andrew, et al. Bayesian data analysis, 3rd edition. Chapman and Hall/CRC, 2013.
4. Дрейпер, Норман Р. Прикладной регрессионный анализ. Рипол Классик, 2007.
5. Chen, Ming-Hui, and Joseph G. Ibrahim. "Conjugate priors for generalized linear models."Statistica Sinica (2003): 461-476.
6. Fahrmeir, Ludwig, and Heinz Kaufmann. "Consistency and asymptotic normality of the maximum likelihood estimator in generalized linear models."The Annals of Statistics (1985): 342-368.
7. Baghishani, Hossein, and Mohsen Mohammadzadeh. "Asymptotic normality of posterior distributions for generalized linear mixed models."Journal of Multivariate Analysis 111 (2012): 66-77.